



이정훈

AI Application Engineer

Agentic AI 시스템 및 LLM 플랫폼 엔지니어링을 중심으로, 프롬프트 엔지니어링·RAG 최적화부터 LLM Judge 기반 평가 파이프라인까지 AI 서비스 개발 전반을 경험해왔습니다

PROFILE

Location: Pangyo, Korea Republic of (GMT +09:00)

Email: leejh9226@gmail.com

Linkedin: <https://www.linkedin.com/in/grayr00m>

Github: <https://www.github.com/grayroom>

WORK EXPERIENCE

kakaobank

2024.11 -

AI프로덕트개발팀

AI Backend Engineer

No-Code LLM API 플랫폼 개발

대고객 서비스 | 2025. 08 ~

- GUI 기반 선언형 워크플로우 정의를 통해 LLM API를 구성·배포할 수 있는 내부 플랫폼 개발
- 반복 사용되는 LLM 파이프라인 로직(입·출력 가드레일, 데이터변환) 모듈화를 통해 LangGraph 워크플로우 표준화 및 서비스 간 중복 구현 제거
- DeepEval·Langfuse 기반 배치 테스트 자동 평가 파이프라인 구축, 프롬프트 버전별 품질 추적
- Amazon API Gateway 기반 테넌트(Tenant)별 유량제어 도입을 통해, 업스트림 vLLM 서버 부하 제어 및 서비스 안정성 확보
- 선언형 LLM API 생성 GUI 개발을 통해 플랫폼 적용 서비스 확대 (서비스 1건 → 10건)
- Fumadocs 기반 가이드 및 Agent Skills 제공을 통한 별도 온보딩 제거 및 플랫폼 사용성 개선

카카오뱅크 앱 “AI 초대장” 서비스 개발

대고객 서비스 | 2025. 08 ~ 2026.02

- 상대 낱자·음력 등 다양한 자연어 일정 표현을 안정적으로 처리하기 위해 structured output 기반 extraction pipeline 최적화 (qwen3 30B A3B, accuracy: 95%)
- Query Rewriting을 통한 OpenSearch 이미지 검색 성능 개선 (precision 70% → 85%)

카카오뱅크 앱 “AI 이체” 서비스 개발

대고객 서비스 | 2025. 03 ~ 2025.11

- LangChain Tool 인터페이스 기반 금융 채널서버 연동 및 LangGraph State를 활용한 출금계좌 변경 기능 개발
- 내부 기능 테스트를 위한 Bulk Test 및 STT 기능을 포함한 Playground 개발

사내 Agentic 챗봇 서비스 개발

사내 서비스 | 2024.11 ~

- ReAct-style 에이전트 워크플로우 설계 및 내부 생산성 툴 개발
- Agit, Confluence등 사내 시스템 연동을 위한 MCP 클라이언트 개발, 내부 SSO, OIDC(Keycloak) 인증과 연계할 수 있도록 커스텀
- 재시도, 취소, 체크포인트 기능을 갖춘 RAG 파이프라인 개선을 통해, 장시간 실행에도 안정적인 RAG 데이터 적재 가능하도록 개선

MADUP

2024.07 - 2024.11

테크사업부 / Creative Team

Backend Developer

광고 성과분석 서비스 “Lever Xpert”

대고객 서비스 | 2024.07 ~

- Apache Airflow 기반 배치 유지보수
- 광고 성과분석 대시보드 다중 필터링 로직 개발 등 유지보수

WORK EXPERIENCE

NAVER Cloud

2024.01 - 2024.07

Digital Healthcare Lab
인턴 · Backend Developer

RAG-LLM 기반 건강검진 챗봇 서비스 POC

POC | 2024.01 ~ 2024.07

- FastAPI, WebSocket 기반 채팅 API 및 Context 관리
- 질병 판단 로직 개선을 통해, 판단 로직 rule data 저장 공간 80% 절감 및 확장성 확보
- 질병 판단 및 외부 검진 데이터 조회 LangChain Runnable 개발

Acryl

2023.07 - 2024.01

디지털혁신본부 개발팀
Backend Developer

보훈인물 3D 디지털 휴먼 복원 사업

대고객 서비스 | 2023.09 ~ 2023.12

- FSM 플로우(착석 → 대기 → 발화 → 답변) 기반의 대화 Turn 관리 기능 개발
- Vision, Audio, 3D, LLM 모듈간 MQTT 기반 상태 동기화 및 Failure 대응
- 오디오 Volume Normalize, BPF, Clipping을 통한 STT 인식을 개선

EDUCATION

광운대학교

2018.03 - 2024.02

컴퓨터공학 전공
(GPA: 4.03/4.5)
컴퓨터과학 학술동아리

투자모델을 위한 백테스팅 플랫폼

광운대학교 | 연구실 외주 | 2023.01 ~ 2023.06

- Vue.js, Echart.js 기반 매수/매도 시점에 따른 포트폴리오 평가지표 시각화
- Write-Through 캐시 활용, 주가 데이터 조회 성능 최적화 (응답 시간 90% 감소)

자연어처리기반 전자의무기록 시스템

광운대학교 | 졸업작품 | 2022.08 ~ 2023.03

- Distill BERT 기반, 처방전 속 주요 키워드를 추출하는 의무기록(EMR)서비스
- 교내 산학협력 SW프로젝트 전시회 최우수상 / 졸업작품 전시회 우수상

Publication & Teaching

[도서] LangGraph로 만드는 AI 에이전트 서비스

성안당 | 공동저자 | 2026.05 출간

- LangGraph, LangChain 기반 AI 에이전트 개발에 필요한 오픈소스 소개
- 프롬프트 엔지니어링, RAG 등 에이전트 설계기법 소개

[강의] 사내 AI 강의 진행

한국통신학회 동계종합학술발표회 | 1저자 | 2023.02

- LangChain, LangGraph 기반 AI 서비스 개발 강의

[졸업논문] 의료인공지능 인터페이스를 갖춘 의료정보시스템 연구

한국통신학회 동계종합학술발표회 | 1저자 | 2023.02

- 의료 AI 실용화 가속화를 위한 지능형 병원정보시스템 모델 제안
- BERT 기반 NER 모델을 활용, 처방전 속 주요 키워드 추출

No-Code LLM API 플랫폼

kakaobank / AI Backend Engineer

배경

운영중인 서비스 전반에 AI feature를 도입하기 위해, 기존에는 아래와 같은 과정을 거치게 됩니다.

- ① 1-2명의 AI Engineer를 배정, 관련 비즈니스 로직 파악 [1 M/M]
- ② 요구사항에 따른 POC 및 기획 Align [1 M/M]
- ③ 서비스 BE와 스펙 합의 및 운영개발 [2-3 M/M]

일반적인 SDLC를 따르는 구조였으나, 요구사항 합의 및 POC 단계에서 유사한 구현을 반복하게 되어 개발 리소스가 비효율적으로 소모되고 있었습니다. 또한 전사 내 유일한 AI 서비스 개발 조직으로서, 다양한 서비스 도메인의 요구사항을 동시에 대응하기 위해 한정된 개발 리소스를 보다 효율적으로 활용할 수 있는 구조가 필요했습니다.

관찰

기존 LangGraph 기반 플랫폼에서는 앞서 언급한 과정을 거쳐 여러 에이전트 서비스가 운영되고 있었습니다. 서비스별 목적과 도메인은 상이했지만, 실행 구조를 분석한 결과 다음과 같은 공통적인 사이클로 수렴함을 확인할 수 있었습니다.

- [전처리] LLM 호출 이전에 RAG, 내부 API 호출 등을 통해 컨텍스트를 구성
- [LLM 호출] 서비스 요구사항에 맞춰 작성된 프롬프트와 컨텍스트를 모델에 전달
- [후처리] LLM 결과를 바탕으로 추가 API 호출 또는 최종 응답 생성

해결·성과

기존의 문제점과 구조적 관찰을 바탕으로, 비즈니스 로직은 완전히 배제하고, AI 서비스에 공통적으로 요구되는 기능만을 조합하여 API 형태로 제공함으로써, LLM 실행 계층을 독립적인 플랫폼 레이어로 재구성했습니다.

LLM API는 아래와 같은 정보를 GUI를 통해 선언적으로 설정할 수 있도록 설계했습니다.

- ① 모델선택 및 원하는 출력형태 정의 (Structured Output, AI Message 등)
- ② 전처리 후처리 모듈 선택 (날짜 추출, 데이터 변환, OpenSearch 등)
- ③ 서비스 요구사항을 반영한 Prompt Template

[API 자동 생성] 시스템 프롬프트와 관련 설정만 추가하면, 요청 스키마를 검증하고 LLM에 전달하여 출력 스키마에 맞는 응답을 내려주는 API가 자동생성 됩니다.

[공통 모듈화] 여러 서비스에 걸쳐 재사용되는 가드레일, 날짜정보 추가 등의 공통로직을 GUI에서 선택 가능한 모듈 형태로 제공합니다.

[책임 분리] 생성한 LLM API는 “날짜 추출”, “문구 생성” 등 이전보다 더 작은 책임을 갖게 됩니다. 그 결과 더 작은 단위로 테스트, 개선, 배포 할 수 있게 되었습니다.

[모델 풀] 또한 모델선택 단계에서 기존에는 POC단계에서 서빙을 담당하는 부서와 리소스 합의가 필요했으나, 미리 연동된 모델 풀을 확보하여 빠르게 서로 다른 모델을 실험 해 볼 수 있게 되었습니다.

[벌크 테스트 및 평가] 생성한 LLM API를 벌크 테스트하고, Deep Eval기반의 벤치마크를 수행할 수 있도록 했습니다. 이를 통해 LLM API 버전별 개선 이력을 관리하고 평가할 수 있게 되었습니다.

플랫폼 영향력

프롬프트와 약간의 설정만으로 운영 가능한 LLM API가 생성된다는 간편함으로, 여러 AI프로젝트에 활용될 수 있었습니다. 2026년 2월 출시한 “AI초대장” 서비스 이외에도 여신·수신 도메인의 다수 AI 프로젝트(10건)에 동시에 적용하거나 도입을 검토 중에 있습니다.

건강검진 챗봇 서비스 POC

NAVER Cloud / 백엔드 개발자 (인턴)

배경

사용자가 건강검진 결과지를 제공하면, 결과에 대해 질의하고 답변을 받아볼 수 있는 서비스를 개발했습니다. 프로젝트에서 크게 두가지 역할을 담당했습니다.

- ① **데이터 전·후처리**: 사용자의 검진 기록을 불러오고, 수치 데이터의 조합에 기반한 정상/비정상 판별 로직을 LangChain Runnable으로 제공
- ② **채팅 인터페이스**: WebSocket 기반 스트리밍 채팅 인터페이스 제공

세부사항

데이터 전·후처리

사용자의 동의에 따라, 스크래핑을 활용하여 건강보험공단의 건강검진 기록 데이터를 획득하였습니다. 이렇게 획득한 데이터에는 각 측정항목별 수치(numeric, Boolean) 데이터가 포함되어 있습니다.

검진 측정치는 대부분 다른 여러 측정치와 복합적인 판단을 필요로 합니다. 이런 복합적인 판단 로직을 여러 측정치에 적용하기 위해 가장 먼저 정상/비정상 판단 로직을 설계하였습니다.

병명	음주횟수 최솟값	음주횟수 최댓값	혈압 최솟값	혈압 최댓값	...	판단결과
고혈압	-	3	-	100		정상
고혈압	-	3	100	120		정상
고혈압	-	3	120	-		위험
고혈압	3	-	-	100		정상
고혈압	3	-	100	120		위험
고혈압	3	-	120	-		위험

각 질병마다 복합적인 판단 기준치를 갖고 있기에, 위와 같이 **정규화된 기준**을 사용할 경우 검진표에 등장하는 모든 측정치 만큼의 속성 정보를 기록하여 **대부분의 속성값이 비어있게** 됩니다. 또한 **새로운 측정치가 추가되는 경우에 테이블 스키마를 변경**해야 한다는 단점이 있었습니다.

이런 공간 복잡도를 낮추기 위해 고민한 결과, 대부분의 질병 판단 로직에는 극소수의 측정치 정보만이 포함되어 데이터가 **희소함**을 발견할 수 있었습니다.

	~ 3회	3회 ~
~ 100mmHg	정상	정상
100mmHg ~ 120mmHg	정상	위험
120mmHg ~	위험	위험

이러한 관찰에 기반하여, 각 질병마다 **카르노 맵(Karnaugh Map)기반의 진리표 판단로직**을 설계하여 MongoDB에 적재하여, 질병 판단로직의 **공간 효율성을 최적화** 하고 **새로운 측정치 추가에도 쉽게 대응**할 수 있게 개선하였습니다.

이렇게 구현된 질병 판단로직은 **LangChain Runnable** 인터페이스를 통해 건강검진 챗봇의 답변 생성 Chain에 활용하였습니다.

채팅 인터페이스

대화형 서비스 구현의 주요한 목표 중 하나는, 사용자가 대화 세션을 떠나지 않도록 짧은 시간내에 정보를 명확하게 전달해야 한다는 것입니다. 이를 위해, TTFT(Time to First Token)를 개선하기 위해 WebSocket 기반의 스트리밍과 카드 UI 대응을 위한 커스텀 메시지 타입을 정의했습니다.

WebSocket은 양방향 스트림을 지원하기에, 세션이 유지되는 동안 답변을 중지 시키거나 추가 정보를 전달하는 등 기능 확장에 이점을 가질 수 있었습니다.

또한 명확한 정보 전달과 부족한 정보를 얻는 HITL(Human-In-The-Loop) 구현을 위해 커스텀 메시지 타입을 정의, 유저에게 간단한 폼 입력을 받거나, 질병 판단 결과를 UI를 통해 전달할 수 있었습니다.

보훈인물 디지털 휴먼 복원 사업

Acryl / 백엔드 개발자

배경

보훈인물 전시관에 설치될 키오스크 시스템을 개발했습니다. 모니터, 마이크, 카메라로 구성된 이 키오스크는 사용자 착석을 감지하여 모니터에 3D 가상인물을 렌더링하고, LLM, STT, TTS 기술을 활용해 질문에 대한 응답을 제공합니다.

세부사항

FSM기반 시스템

프레임워크 없이 개발된 이 프로젝트에서는 에러와 무한루프 상태를 방지하는 데 주력했습니다. 이를 위해 시스템의 가능한 N가지 상태들을 미리 정의하고, 특정 조건 충족 시에만 상태 전이가 이루어지는 구조를 설계했습니다. 또한, 시스템 컴포넌트가 예기치 않게 종료되는 경우에도 HealthCheck를 통한 모니터링과 복구 시나리오로 예측 가능한 동작을 보장하도록 구현했습니다.

STT 인식을 개선

키오스크는 관람객과의 실시간 대화를 위해 STT를 사용하여 발화를 인식합니다. 버튼 조작 없이도 말을 걸면 STT가 시작되며, 다양한 말투의 발화를 정확히 이해하는 것이 주요 목표였습니다.

다양한 테스트 음성으로 검증을 수행하던 중, 말끝을 흐리거나 볼륨이 일정하지 않은 경우 인식률이 저하됨을 발견했습니다. 이 문제를 해결하기 위해 STT 수행 전 오디오 청크의 평균 볼륨을 일정 수준으로 Normalize하고, FFT 수행 후 Band-Pass-Filter를 적용하여 목소리만 추출하는 방식을 도입했습니다.

그 결과, 이전에 정확히 인식되지 않던 테스트셋의 80% 이상을 명확히 인식할 수 있도록 개선했습니다.